

AI의 기초: Raw Data와 Label 쉽게 이해하기

한 줄 요약

AI를 가르치려면 ****문제(Raw Data)****와 ****정답(Label)****이 필요합니다.

1. Raw Data란?

****Raw Data(원시 데이터)****는 AI에게 보여주는 **가공되지 않은 원본 자료**입니다.

우리 주변의 거의 모든 것이 Raw Data가 될 수 있습니다:

종류	예시
사진	길거리에서 찍은 자동차 사진
소리	사람이 말하는 음성 녹음
글	인터넷에 올라온 상품 후기
숫자	온도센서가 측정한 온도 값
영상	CCTV에 녹화된 동영상

비유: 시험 문제지

Raw Data는 **시험의 문제지**와 같습니다.

문제: 다음 사진 속 동물은 무엇일까요?

 사진

← 이것이 Raw Data

문제지만 있으면 학생(AI)은 공부할 수 없습니다. **정답지**가 필요하죠.

2. Label이란?

****Label(라벨)****은 Raw Data에 사람이 붙여주는 **정답 태그**입니다.

"이 사진은 고양이야", "이 음성은 '안녕하세요'라고 말하는 거야" 처럼 **사람이 직접 알려주는** 답입니다.

비유: 시험 정답지

문제 (Raw Data)		정답 (Label)
 사진	→	"고양이"
 사진	→	"개"
 사진	→	"자동차"

3. AI는 이걸로 어떻게 배우나요?

사람이 공부하는 방식과 똑같습니다:

사람의 공부

1. 문제를 본다

→ "이 사진 속 동물은?"
2. 정답을 확인한다

→ "고양이었구나"
3. 수백 번 반복한다

→ "이런 특징이면 고양이!"
4. 새 문제를 맞힌다

→ 처음 보는 고양이 사진도 맞춤

AI의 학습

1. Raw Data를 입력


→ 고양이 사진을 넣음
2. Label과 비교

→ "고양이"라는 정답과 비교
3. 수만 번 반복


→ 패턴을 스스로 발견
4. 새 데이터에 적용

→ 처음 보는 사진도 "고양이"라고 맞춤

그림으로 보기



사용 단계 (Inference)



4. 라벨링의 종류

데이터에 정답을 붙이는 방식은 여러 가지가 있습니다:

4-1. 분류 (Classification)

"이것은 무엇인가요?"

사진 → "고양이"

사진 → "개"

리뷰 → "긍정" 또는 "부정"

가장 기본적인 형태. 전체 데이터에 카테고리 하나를 붙입니다.

4-2. 위치 표시 (Object Detection)

"어디에 무엇이 있나요?"






사진 속에서 물체의 **위치(바운딩 박스)**와 **이름**을 함께 라벨링합니다.

4-3. 영역 칠하기 (Segmentation)

"정확히 어느 부분이 무엇인가요?"





의료 영상(CT, X-ray)에서 종양 영역을 표시할 때 많이 사용합니다.

4-4. 수치 예측 (Regression)

"얼마인가요?"

집 사진 → "3억 5천만 원"

환자 데이터 → "혈당 수치 120"

카테고리가 아니라 **연속적인 숫자 값**을 라벨로 붙입니다.

5. 라벨이 없으면 어떻게 하나요?

라벨이 항상 필요한 것은 아닙니다. AI 학습 방식에 따라 다릅니다:

학습 방식	라벨 필요?	쉬운 설명
지도학습	○ 필요	선생님이 정답을 알려주며 가르침
비지도학습	✗ 불필요	학생이 스스로 비슷한 것끼리 분류
자지도학습	✗ 불필요	문장의 빈칸을 스스로 채우며 학습 (ChatGPT 방식)
반지도학습	△ 조금만	소수의 정답 + 대량의 무정답 데이터 활용

비유로 이해하기

지도학습: 선생님이 "이건 고양이야" 하나하나 알려줌

비지도학습: 아이가 동물원에서 "이것들은 비슷하게 생겼네!" 스스로 발견

자지도학습: "고양이는 ___를 좋아한다" 빈칸 채우기를 수만 번 반복

6. 실생활 예시

예시 1: 스팸 메일 필터

Raw Data (이메일 내용)	Label
"축하합니다! 1억 당첨!"	→ 스팸

"내일 회의 10시에 합시다"	→ 정상
"지금 바로 클릭하세요!!!"	→ 스팸
"프로젝트 진행상황 공유합니다"	→ 정상

이렇게 수만 건의 이메일에 "스팸/정상" 라벨을 붙여 학습시키면, 새 이메일이 와도 자동으로 스팸을 걸러냅니다.

예시 2: 번호판 인식 (LPR)

Raw Data (차량 사진)	Label
차량 사진 1	→ "12가 3456"
차량 사진 2	→ "서울 78나 9012"
차량 사진 3	→ "34다 5678"

예시 3: 음성 인식

Raw Data (음성 파일)	Label
음성 1	→ "오늘 날씨 어때?"
음성 2	→ "알람 7시에 맞춰줘"
음성 3	→ "노래 틀어줘"

7. 왜 라벨링이 그렇게 중요한가?

"쓰레기를 넣으면 쓰레기가 나온다" (Garbage In, Garbage Out)

✗ 잘못된 라벨:

사진 → "개" (오답)
→ AI가 고양이를 보고 "개"라고 학습
→ 틀린 AI 완성!


✓ 올바른 라벨:

사진 → "고양이" (정답)
→ AI가 올바르게 학습
→ 정확한 AI 완성!

라벨링의 현실

- AI 성능의 **70~80%**는 데이터와 라벨의 품질이 결정합니다
- 좋은 AI 모델을 만드는 것보다 **좋은 데이터를 모으는 것이 더 어렵습니다**
- 라벨링은 **사람이 직접** 해야 하므로 비용과 시간이 많이 듭니다
- 이 라벨링 작업을 전문적으로 해주는 회사가 있을 정도입니다 (예: Scale AI — 기업 가치 약 19조 원)

8. 한 눈에 정리



용어	한 줄 설명
Raw Data	AI에게 보여주는 원본 자료 (사진, 음성, 텍스트 등)
Label	사람이 Raw Data에 붙인 정답 태그
라벨링	Raw Data에 Label을 붙이는 작업
학습(Training)	Raw Data + Label로 AI를 가르치는 과정
추론(Inference)	학습된 AI가 새 데이터를 보고 답을 예측하는 것

작성일: 2026-04-11