

On-Device AI — 정의와 연구 방향

본 문서는 **onDevice_AI vault**의 헌법 역할. 모든 검증·연구·시장조사·영업 매핑은 이 정의를 출발점으로 한다. 정의가 흔들리면 방향이 흔들리므로, 갱신은 신중히 하되 누적해서 기록한다.

1. 한 줄 정의

On-Device AI는 AI 추론(inference)을 클라우드 서버가 아닌, 기기 자체의 하드웨어에서 직접 수행하는 방식.

"Trained on Cloud, Inferred on Edge" — 학습은 클라우드 대형 GPU에서, 추론은 디바이스(MCU·NPU·모바일 SoC)에서.

2. 핵심 대비 구조

구분	Cloud AI	On-Device AI
연산 위치	원격 GPU 서버 (AWS·GCP)	로컬 칩 (MCU·NPU·모바일 SoC)
네트워크	필수 (왕복 지연)	불필요 (오프라인 동작)
데이터 흐름	입력→서버 전송→결과 수신	입력→로컬 추론→결과
모델 크기	수십 GB~수 TB 가능	수 KB~수백 MB (양자화·경량화 필수)
비용 구조	API 호출당 과금	1회 모델 배포 후 무료
개인정보	외부 서버 경유	기기 외부로 안 나감

3. AI 관점에서의 기술적 본질

본 vault에서 다루는 "AI"는 **추론 단계**에 한정. 학습은 외부 GPU에서 수행하고, 검증 대상은 **"학습된 모델을 어떻게 작은 칩에 육여넣고 실시간으로 돌릴 것인가"**.

3.1 이를 가능하게 하는 4대 핵심 기술

- 양자화(Quantization)** — FP32 → INT8/INT4로 모델 메모리 1/4~1/8 축소
- 프루닝(Pruning)** — 불필요한 가중치 제거 (희소화)
- 지식 증류(Knowledge Distillation)** — 대형 모델(teacher) → 소형 모델(student) 능력 이전
- NPU/MCU 가속** — 전용 신경망 연산 하드웨어로 전력·속도 동시 최적화

3.2 vault 검증의 위치

본 vault는 **양자화 + 작은 모델 + MCU 가속**의 교집합을 검증.

- 양자화: microGPT FP32 16.4KB → INT8 4.1KB (5/8 실측)
- 작은 모델: Karpathy 200줄 GPT (4,192 params), Korean-Small (154K params)
- MCU 가속: ESP32-S3 SRAM 520KB 한계 내 추론

4. On-Device AI의 4대 가치 (왜 On-Device인가)

가치	본질	적용 영역
Privacy	데이터가 기기 밖으로 안 나감	의료·금융·개인정보·기업 비밀
Latency	네트워크 왕복 제거	실시간 음성·영상·로봇 제어
Offline	네트워크 없이 동작	드론·산업현장·산간·차량
Cost	API 호출 비용 0	대량 배포 (수만~수백만 대)

이 4가지 중 어느 하나라도 강하게 요구되면 On-Device AI가 답이 됨. 본 vault의 검증은 **Cost + Offline** 축(8달러 MCU 대량 배포)이 핵심이고, **Privacy + Latency**는 부수 가치로 따라옴.

5. On-Device AI의 스펙트럼 (어디까지가 On-Device인가)

본 vault는 **가장 극단적인 끝(MCU급)** 을 검증. 스펙트럼 전체는 다음과 같다:

티어	하드웨어	메모리	모델 크기 예시	본 vault 관련성
T1 MCU급	ESP32-S3, Cortex-M4	RAM 512KB	microGPT 4K params (INT8 4KB)	✅ 메인 검증
T2 SBC급	Raspberry Pi, Jetson Nano	RAM 4~8GB	TinyLlama 1.1B (Q4 650MB)	⚠️ 시장조사 대상
T3 모바일급	iPhone, Snapdragon X2	RAM 8~16GB	Llama 3 8B (Q4 4GB)	⚠️ 시장조사 대상
T4 노트북급	Apple M5, AMD Ryzen AI	RAM 16~64GB	Llama 3 70B (Q4 35GB)	❌ 범위 외

왜 T1에 집중하는가: UTTEC의 강점(임베디드 38년) + 시장 공백(T1에서 LLM이 도는 사례 거의 없음) + 영업 임팩트 (Stage 4 1,500만 패키지의 차별점).

6. 본 vault의 연구 방향 — 정의에서 파생되는 질문들

정의가 정해지면, 검증 가설은 다음 5축에서 파생된다. 새 검증을 시작할 때 **"어느 축의 어느 질문에 답하는가"** 를 명시할 것.

6.1 모델 축 — "얼마나 작아질 수 있는가"

- Q1. ESP32-S3 SRAM 520KB에서 실용적 작업을 하는 최소 모델 크기는?
- Q2. 4K~154K 파라미터 사이에서 task별 최소 크기 곡선은?
- Q3. Knowledge Distillation으로 GPT-2 small(124M) → ESP32 탑재 가능 크기로 압축 가능한가?

6.2 하드웨어 축 — "어느 칩까지 내려갈 수 있는가"

- Q4. ESP32-S3 외에 ESP32-C3 / Cortex-M4F / RP2040 등 더 저렴한 칩은?
- Q5. NPU 내장 MCU(예: K210, Maix)와 범용 MCU의 추론 속도 비교는?

- Q6. ESP32-S3 + 외장 PSRAM(8MB) 조합의 실효 모델 크기 상한은?

6.3 응용 축 — "어떤 task가 T1 티어에 적합한가"

- Q7. AI FanStick: 음원 패턴 학습(SLM 4K~10K) 가능한가?
- Q8. 음성 키워드 인식(KWS)·환경음 분류 등 검증된 task의 모델 크기 분포는?
- Q9. T1에서 "언어"가 의미 있는 task는? (대화 X, 명령 분류 O)

6.4 양자화 축 — "정확도 손실 어디까지 감내하는가"

- Q10. FP32 vs INT8 vs INT4의 task별 정확도 손실은?
- Q11. Mixed precision(가중치 INT8 + 활성화 INT16) 적용 시 SRAM·정확도 trade-off는?
- Q12. ESP32-S3의 SIMD 명령(DSP)을 활용한 INT8 추론 가속은?

6.5 영업·시장 축 — "정의를 어떻게 가치로 전환하는가"

- Q13. T1 On-Device AI의 시장 규모와 경쟁자(STMicro·Edge Impulse·TensorFlow Lite Micro)는?
- Q14. UTTEC의 차별화 포인트는 무엇인가? (기술 / 가격 / 통합 / 교육)
- Q15. Stage 4 영업 패키지 1,500만의 기술 근거 1건당 수주율 영향은?

7. 정의에서 나오는 검증의 우선순위

본 vault의 진행 우선순위는 정의의 어느 축이 가장 큰 영업 임팩트를 주는가에 따라 결정된다.

현재 우선순위 (2026-05-15 기준):

1. **응용 축 Q7** — AI FanStick 학습 시나리오 (✅ 4 경로 완료)
2. **모델 축 Q1** — ESP32-S3 SRAM 최대 모델 (✅ 분석 완료, 🟪 보드 실측 대기)
3. **양자화 축 Q10** — FP32 → INT8 정확도 손실 (✅ 분석, 🟪 실측 대기)
4. **하드웨어 축 Q4** — 더 저렴한 칩 (🟪 Phase 2 이후)
5. **영업 축 Q14** — 차별화 포인트 (🟪 검증 결과 후 정리)

8. 갱신 이력

일자	변경	동기
2026-05-15	초안 작성	사용자 요청 — 정의를 바탕으로 연구 방향을 정리해야 함을 인식

9. 본 정의가 흔들릴 수 있는 조건

다음 중 하나라도 발생하면 본 정의를 재검토:

- **하드웨어 가격 급변**: ESP32-S3 가격이 5달러 이하로 하락하거나, NPU MCU(K210 등)가 1달러대 진입
- **알고리즘 돌파**: 1-bit Quantization·State Space Model 등이 MCU급에서 실용화
- **시장 변곡**: T1 티어 사용처가 마케팅에서 양산으로 이동 (현재 정지선 2026-05-08 해제 조건)
- **법규 변화**: EU AI Act·국내 AI 기본법 등이 On-Device 추론을 의무화하거나 금지

10. 참조

- 시장 동향 (정의의 시장적 근거): [시장조사/README.md](#) (11 섹션 종합)
- 검증 매트릭스 (정의의 실증): [0_검증계획.md](#)
- vault 검토 순서: [00_검토순서.md](#)
- 외부 entity: [myWiki/second-brain/entities/onDevice-ai.md](#)